

Tarea C — Recuperación léxica contra semántica latente sobre un corpus mínimo

MMIA 6013 · Tarea de práctica para el solver del Taller 03 v2 Entrega: un reporte en **PDF** (`reporte.pdf`) de dos páginas como máximo, con el código.

El corpus son diez documentos cortos y las consultas son seis, cada una con **un** documento relevante. Los datos están completos en este enunciado: no hace falta descargar nada.

Corpus

id	texto
d01	El mecanismo de atención pondera cada token según su similitud con la consulta; la atención escalada divide por la raíz de la dimensión.
d02	Los transformadores apilan capas de autoatención y redes feed-forward, con conexiones residuales y normalización.
d03	La recuperación aumentada con generación busca fragmentos relevantes y los añade al prompt del modelo.
d04	BM25 es una función de ranking léxica que pondera la frecuencia de términos y la longitud del documento.
d05	Los embeddings densos representan textos como vectores; la similitud coseno compara su orientación.
d06	Un agente con herramientas decide en cada paso qué función llamar y observa el resultado.
d07	ReAct intercala razonamiento y acciones; Reflexion añade una autocrítica verbal entre intentos.
d08	El ajuste fino con LoRA entrena matrices de bajo rango y congela los pesos originales.
d09	La temperatura reescala los logits antes del softmax; valores bajos concentran la probabilidad.
d10	La cuantización reduce la precisión de los pesos a 8 o 4 bits para ahorrar memoria.

Consultas y juicios de relevancia

id	consulta	relevante
q1	¿Qué función de ranking léxica pondera la frecuencia de términos?	d04
q2	¿Cómo se añaden fragmentos recuperados al prompt?	d03
q3	¿Qué técnica entrena matrices de bajo rango?	d08
q4	¿Cómo se compara la orientación de dos vectores de texto?	d05
q5	¿Qué hace que el modelo sea más determinista al elegir la siguiente palabra?	d09
q6	¿Qué arquitectura combina autoatención con capas feed-forward?	d02

Parte 1 — Línea base léxica

Implementa la recuperación con TF-IDF (`TfidfVectorizer` de scikit-learn con sus parámetros por defecto) y similitud coseno. Para cada consulta, ordena los diez documentos. Reporta **Hit@1**, **Hit@3** y **MRR** sobre las seis consultas.

Parte 2 — Semántica latente

Con las mismas consultas y los mismos juicios, proyecta la matriz TF-IDF a 4 dimensiones con `TruncatedSVD(n_components=4, random_state=0)` (LSA) y repite la evaluación. Reporta las tres métricas de los dos métodos en una sola tabla.

Parte 3 — Análisis por consulta

Identifica en qué consultas falla cada método (el relevante fuera del top 3) y explica por qué, mirando qué términos comparten la consulta y su documento relevante.

Parte 4 — Pregunta conceptual

¿Por qué un recuperador denso (embeddings de un modelo entrenado) resolvería la consulta q5 mejor que los dos métodos de esta tarea? ¿Qué costo tiene frente a TF-IDF?

El reporte

En PDF, dos páginas como máximo, con las secciones **Objetivo**, **Método**, **Resultados** (la tabla de la Parte 2 y la de la Parte 3) y **Discusión**. Toda cifra sale de la ejecución.

